

CAP 1: Distributions conjuntas, condiciones e independencia.

Df. (vector aleatorio) Un vector aleatorio

k -dimensional $x = (x_1, \dots, x_k)^T$ es una

función (medible) desde el espacio de

probabilidad Ω a \mathbb{R}^k , esto es,

$$x: \Omega \rightarrow \mathbb{R}^k.$$

que asigna un vector $x(\omega)$ a cada

resultado ω .

Df: Siempre tenemos k variables aleatorias

sobre el mismo espacio.

Por ejemplo, para

un paciente se puede recolectar la

información de su edad, presión sanguínea,

sexo, etc., nivel de colesterol.

Para introducir algunos ideas consideremos el caso $p=2$ para posteriormente revisar las definiciones generales ($p > 2$).

Distribuciones bivariadas.

Para un par de variables aleatorias x e y , se tiene la función de densidad conjunta como $f(x, y) = P(x=x, y=y)$.

Notación: llamaremos

$$P(x=x, y=y) = P(\{x=x\} \cap \{y=y\}).$$

Ejemplo: distribución bivariada con x e y tomando valores 0 o 1.

| $x \backslash y$ | 0 | 1 | |
|------------------|-------|-------|-------|
| 0 | $1/9$ | $2/9$ | $1/3$ |
| 1 | $3/9$ | $4/9$ | $2/3$ |
| | $1/3$ | $2/3$ | 1 |

en este caso tenemos que

$$f(1,1) = P(X=1, Y=1) = \frac{4}{9}$$

Def: Decimos que $f(x,y)$ es la función de densidad del vector aleatorio (X,Y) si

(i) $f(x,y) \geq 0$ para todos (x,y) ,

(ii) $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x,y) dx dy = 1$,

(iii) Para cualquier conjunto $A \subset \mathbb{R}^2$,

$$P((X,Y) \in A) = \iint_A f(x,y) dx dy$$

Obs: Stark el caso de distribuciones discretas.
La definición es análoga.

(*) (Revisar definición en el ejemplo anterior)

Ejemplo: Sea (x, y) una densidad

$$f(x, y) = \begin{cases} x+y, & 0 \leq x \leq 1, 0 \leq y \leq 1, \\ 0, & \text{en otro caso} \end{cases}$$

entonces.

$$\begin{aligned} \int_0^1 \int_0^1 (x+y) dx dy &= \int_0^1 \left[\int_0^1 x dx \right] dy \\ &+ \int_0^1 \left[\int_0^1 y dx \right] dy = \int_0^1 \frac{1}{2} dy + \int_0^1 y dy \\ &= \frac{1}{2} + \frac{1}{2} = 1. \end{aligned}$$

es decir f es una densidad.

La distribución conjunta de (x, y) puede ser completamente caracterizada mediante la función de distribución conjunta (cdf), $F(x, y)$ definida como

$$F(x, y) = P(x \leq x, y \leq y).$$

La función de distribución acuática tiene las siguientes propiedades:

- (i) $f(+, j)$ es función monótona creciente y continua a la derecha en $(+, j)$.
- (ii) $0 \leq f(+, j) \leq 1$.
- (iii) $f(-\infty, j) = f(+, -\infty) = 0$.
- (iv) $f(+\infty, +\infty) = 1$.

Análoga al cdf no es muy apropiada para el caso discreto, pero tiene las siguientes relaciones de interés

$$f(+, j) = \int_{-\infty}^{+\infty} \int_{-\infty}^j f(s, t) dt ds.$$

Ahí, desde el Teorema fundamental del Cálculo sigue que

$$\frac{\partial^2 f(+, j)}{\partial x \partial y} = f(+, j).$$

DESEMPEÑO Sea (x, γ) un vector aleatorio bivariado con distribución conjunta $f_{x, \gamma}(x, \gamma)$

entonces las distribuciones marginales de x e γ , $f_x(x) = P(x=x)$ y $f_\gamma(\gamma) = P(\gamma=\gamma)$ son respectivamente dadas por

(a) Para el caso discritos:

$$f_x(x) = \sum_j f(x, j) = \sum_j P(x=x, \gamma=j)$$

$$f_\gamma(j) = \sum_x f(x, j) = \sum_x P(x=x, \gamma=j)$$

(b) Para el caso de variables continuas.

$$f_x(x) = \int_{-\infty}^{\infty} f(x, j) dj, \quad f_\gamma(j) = \int_{-\infty}^{\infty} f(x, j) dx$$

DEM: Sobre caso (a). Considera $f_x(x)$, entonces para cualquier $x \in \mathbb{R}$, sea

$$S_x = \{(x, j) : -\infty < j < +\infty\}$$

(este es S_x es la linea en el plano con la coordenada igual a x)

De este modo, para $x \in \mathbb{R}$

$$\begin{aligned}
 f_x(x) &= P(X=x) = P(X=x, -\infty < Y < \infty) \\
 &\quad (\text{pues } P(-\infty < Y < +\infty) = 1) \\
 &= P((X, Y) \in S_x) \quad (\text{por la def de } S_x) \\
 &= \sum_{(x, y) \in S_x} f_{X,Y}(x, y) \\
 &= \sum_j f_{X,Y}(x, j).
 \end{aligned}$$

Ejemplo: Supongamos que

$$f_{X,Y}(x, y) = e^{-(x+y)}, \quad x, y \geq 0.$$

De este modo

$$f_x(x) = \int_0^{\infty} e^{-x-y} dy = e^{-x}$$

OBS: Para variables aleatorias continuas podemos usar la siguiente relación

$$\begin{aligned}F_x(x) &= P(X \leq x) = \int_{-\infty}^x f_x(t) dt \\&= \int_{-\infty}^x \int_{-\infty}^{+\infty} f_{x,y}(t, y) dy dx \\&= F_{x,y}(x, +\infty)\end{aligned}$$

Además

$$f_x(x) = \frac{df_x(x)}{dx}$$

y análogamente

$$f_y(y) = f_{x,y}(+\infty, y)$$

Distribuciones condicionales e independencia.

Def. La fracción de densidad condicional para el caso discreto es definida como

$$f_{x|Y}(x|y) = P(x=x \mid Y=y)$$

$$= \frac{P(x=x, Y=y)}{P(Y=y)}$$

$$= \frac{f_{x,y}(x,y)}{f_Y(y)}$$

$$= \frac{f_{x,y}(x,y)}{f_Y(y)}$$

Si $f_Y(y) > 0$

OBS: A pesar de la nomenclatura $f_{x|Y}(x|y)$,

se debe destacar que $f_{x|Y}(x|y)$ es función de x .

Para el caso continuo, tenemos.

$$f_{\alpha|Y}(x|y) = \frac{f_{x,Y}(x|y)}{f_Y(y)}, \quad f_Y(y) > 0.$$

De este modo

$$P(x \in A | Y = y) = \int_A f_{x|Y}(x|y) dx.$$

Obs: Este cálculo de probabilidades con traste con el caso discreto donde no es necesario "integrar" (sumar).

Además note que

$$f_{\alpha|Y}(x|y) = \frac{f_{x,Y}(x|y)}{f_Y(y)}.$$

$$= \frac{f_{Y|X}(y|x) f_X(x)}{f_Y(y)}.$$

$$f_{\alpha|y}(x|y) = \frac{\int_{-\infty}^{\infty} f_{\alpha|x}(y|x) f_x(x) dx}{\int_{-\infty}^{\infty} f_{\alpha|x}(y|x) f_x(x) dx}$$

que corresponde al teorema de Bayes para datos dadas.

OBS: Note que $c = \int_{\mathbb{R}} f_{\alpha|x}(y|x) f_x(x) dx$.

corresponde a la constante de normalización de $f_{\alpha|y}(x|y)$, luego basta calcular

$$f_{\alpha|y}(x|y) \propto f_{\alpha|x}(y|x) f_x(x)$$

Ejemplo: Consideremos $\tau/\sigma \sim N(\mu, \sigma^2/\sigma)$.
 $\tau \sim \text{Gamma}\left(\frac{\alpha}{2}, \frac{1}{2}\right)$. Entonces obtenga la
distribución de $\tau/\sqrt{\tau}$.

solución: Sea $\tau \sim \text{Gamma}(\alpha, \beta)$. Entonces.

$$f_{\tau}(z) = \frac{\beta^{\alpha}}{\Gamma(\alpha)} z^{\alpha-1} e^{-\beta z}, \quad \alpha, \beta > 0, \quad z \geq 0.$$

En esta parametrización de la Gamma tenemos.

que $E(\tau) = \alpha/\beta$.

Note que

$$f_{\tau}(y) = \int_0^{\infty} f_{\tau|x}(x|y) dx$$

con

$$f_{\tau|x}(x|y) = f_{\tau/x}(y|x) f_x(x).$$

$$= (2\pi\sigma^2/\sigma)^{-1/2} \exp\left\{-\frac{x}{\sigma^2} \left(\frac{y-\mu}{\sigma}\right)^2\right\}$$

$$\times \frac{(\sigma/2)^{\sigma/2}}{\Gamma(\sigma/2)} x^{\sigma/2 - 1} \exp\left(-\frac{\sigma}{2} x\right).$$

Ahora

$$\begin{aligned}
 f_{x|\gamma}(x|y) &\propto x^{1/2} \exp\left(-\frac{x}{2}\gamma^2\right) \\
 &\propto x^{1/2-1} \exp\left(-\frac{x}{2}\gamma^2\right) \\
 &= x^{\frac{-1}{2}} \exp\left\{-\frac{1}{2}(\gamma^2 + x)\right\}.
 \end{aligned}$$

que corresponde al "kernel" de una densidad

$$\text{Gauss}\left(\frac{x+1}{2}, \frac{x+\gamma^2}{2}\right) (\stackrel{d}{=} x|\gamma).$$

OBS: En este caso no es necesario

calcular la "desagradable" constante

$f_y(y)$ en la densidad $f_{x|\gamma}(x|y)$.

(Además $x|\gamma$ es del mismo tipo que
y esto ocurre cuando las familias son
conjugadas)

En efecto, la densidad condicional debe satisfacer las condiciones de una densidad dadas anteriormente.

$$\int_{-\infty}^{\infty} f_{Y|X}(y|x) dy = \int_{-\infty}^{\infty} \frac{f_{XY}(x,y)}{f_X(x)} dy$$

$$= \frac{1}{f_X(x)} \int_{-\infty}^{\infty} f_{XY}(x,y) dy = \frac{f_X(x)}{f_X(x)} = 1.$$

Además es obvio que $f_{Y|X}(y|x) \geq 0$.

Los momentos de una v.a. condicional se definen de forma análoga

$$t(\alpha|y) = \int_{-\infty}^{\infty} x f_{\alpha|y}(dy) dx$$

$$t(\alpha|x) = \int_{-\infty}^{\infty} y f_{\alpha|x}(y|x) dy$$

Análogamente

$$\text{Var}(-\gamma|x) = \pm(\gamma^2|x) - (\pm(-\gamma|x))^2$$

Teorema: Considera el vector alcance (x, y) con densidad conjunta.

$$f(x, y) = \bar{e}^y, \quad 0 < x < y < \infty.$$

Para obtener $\text{Var}(-\gamma|x)$ primero se debe calcular la densidad condicional $f(y|x)$.
 $= f(x, y)/f(x)$. Ademas tiene que

$$f_x(x) = \int_{-\infty}^{\infty} f(x, y) dy, \quad y > x$$

$$= \int_x^{\infty} \bar{e}^y dy = \bar{e}^{-x}$$

(si $x \leq 0$ tenemos que $f(x, y) = 0$ para
 cualquier y, y de ahí que $f_x(x) = 0$)

De este modo, para cualquier $x > 0$ (pues $f_x(\alpha) > 0$) tiene mos

$$f(y|\alpha) = \frac{f(x,y)}{f_x(\alpha)} = \frac{\bar{e}^y}{\bar{e}^x} = \bar{e}^{(y-x)}, \quad y > x$$

(mientras que $y \leq x \Rightarrow f(y|\alpha) = f(x,y)/f_x(\alpha) = 0/\bar{e}^x = 0$). De este modo

$$\mathbb{E}(\gamma|x=\infty) = \int_x^\infty y \bar{e}^{(y-\alpha)} dy = \alpha + x$$

y de ahí que

$$\text{Var}(\gamma|x) = \int_x^\infty y^2 \bar{e}^{(y-\alpha)} dy - \left(\int_x^\infty y \bar{e}^{(y-\alpha)} dy \right)^2$$

$$= J$$

DEF. Sea (x, y) un vector aleatorio con distribución conjunta $f(x, y)$ y distribuciones marginales $f_x(x)$, $f_y(y)$, respectivamente. Entonces x e y se dicen independientes si, para todo $x, y \in \mathbb{R}$,

$$f(x, y) = f_x(x) f_y(y).$$

OBS: Analogamente, si $f(x, y)$ representa la función de distribución conjunta del vector (x, y) y $G(x), H(y)$ corresponden a las cdf de x e y , respectivamente. Entonces x e y son independientes si

$$f(x, y) = G(x) H(y).$$

Notación: En ocasiones indicaremos que x e y son independientes como $x \perp y$.

OBS: Note que, f e g son independientes, entonces la densidad conjunta de los datos $x = f$ es dada por

$$f(g|x) = \frac{f(x, g)}{f(x)} = \frac{f_x(x) f_g(g)}{f_x(x)} = f_g(g).$$

RESULTADO Sean f, g variables aleatorias independientes. Entonces.

$$(a) P(x \in A, \gamma \in B) = P(x \in A)P(\gamma \in B)$$

(es decir, los eventos $\{x \in A\}$ y $\{\gamma \in B\}$ son independientes)

(b) Sea $g(x)$ una función sobre x y $h(y)$ una función sobre y . Entonces

$$P\{g(x)h(y)\} = P\{g(x)\}P\{h(y)\}$$

dem: solo parte (b). Tenemos que

$$\begin{aligned}
 \mathbb{E}\{g(x) h(y)\} &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x) h(y) f(x, y) dx dy \\
 &\stackrel{\text{ind}}{=} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x) h(y) f_x(x) f_y(y) dx dy \\
 &= \int_{-\infty}^{\infty} g(x) f_x(x) dx \int_{-\infty}^{\infty} h(y) f_y(y) dy \\
 &= \mathbb{E}\{g(x)\} \mathbb{E}\{h(y)\}.
 \end{aligned}$$

Tarea: probar parte (a). Sugerencia: Usar $g(\cdot)$, $h(\cdot)$ como funciones radiales.

EXTENSIONES AL CASO MULTIVARIADO ($K > 2$)

Sea $\mathbf{x} = (x_1, \dots, x_K)^T$ donde x_1, \dots, x_K son variables aleatorias, dimensión que \mathbf{x} es K -dimensional.

Usaremos la notación $f(\mathbf{x})$, $f(x)$ para indicar las funciones de densidad de distribución del vector aleatorio \mathbf{x} .

$$f(\mathbf{x}) = P(\mathbf{x} \leq \mathbf{x}) (= P(x_1 \leq x_1, \dots, x_K \leq x_K))$$

que corresponde a la probabilidad del evento

$$\bigcap_{i=1}^K \{x_i \leq x_i\}.$$

Por otro lado, afirmamos que existe f no negativa tal que

$$f(\mathbf{x}) = \int_{-\infty}^{\mathbf{x}} f(u) du, \quad \mathbf{x} \in \mathbb{R}^K.$$

11

Además (por el Teorema fundamental del Cálculo)
 tenemos que la fracción de densidad f es
 tal que

$$f(\alpha) = \frac{\partial^k f(x)}{\partial x_1 \cdots \partial x_n}$$

con $\int_{\mathbb{R}^n} f(\alpha) dx = 1$

Considera la siguiente partición $x = (x_1^+, x_2^+)^T$
 donde x_1 y x_2 son vectores $\mathbb{R}_+^{k_1} \times \mathbb{R}_+^{k_2}$ ($k_1 + k_2 = n$).
 $= (\mathbf{x}_1 + \mathbf{x}_2)$. Tenemos que $x_i^+ \sim f_i$ para $i=1,2$.
 al decir x_1 y x_2 son marginales del vector
 x . Además

$$f_1(s) = f(s, +\infty), \quad f_2(t) = f(+\infty, t)$$

para $s \in \mathbb{R}^{k_1}$, $t \in \mathbb{R}^{k_2}$ o alternativa mente

$$f_1(s) = \int_{\mathbb{R}^{k_2}} f(s, w) dw, \quad f_2(t) = \int_{\mathbb{R}^{k_1}} f(w, t) dw$$

$\Leftrightarrow f_1(x) > 0$ en todos los casos de densidad condicional
de x_2 dado $x_1 = x_1$ es clara por

$$f_{x_2|x_1=x_1}(u) = \frac{f_x(x_1, u)}{f_x(x_1)}$$

$$= \frac{f_x(x_1, u)}{\int_{\mathbb{R}^2} f_x(x_1, t) dt}$$

DEF: Si x_1, \dots, x_n son independientes y cada una tiene la misma distribución marginal con CDF F , decimos que x_1, \dots, x_n son IID (independientes e identicamente distribuidas) y escribimos

$$x_1, \dots, x_n \sim F$$

Si F tiene densidad f podemos escribir $x_1, \dots, x_n \sim f$.

OBS. Quando $x_1, \dots, x_n \stackrel{\text{iid}}{\sim} f$ tambien decimos que x_1, \dots, x_n es una muestra aleatoria de f ($\circ f$).

Ademas, si x_1, \dots, x_n son independientes es facil ver que

$$f(\alpha) = \prod_{i=1}^n f_{x_i}(x_i)$$

Casos Importantes:

1. Distribucion Multinomial. Sea $\phi = (\phi_1, \dots, \phi_k)^T$ donde $\phi_j \geq 0$ y $\sum_{j=1}^k \phi_j = 1$, donde ϕ_j representa la probabilidad de éxito asociada a la k -éxito en la j -éxito. Sea $\alpha = (x_1, \dots, x_p)^T$ donde x_j representa el número de veces que se produce el j -éxito. Se $n = \sum_{j=1}^k x_k$

Decimos que $x \sim$ multinomial (n, ϕ)
con función de probabilidad

$$f(x) = \binom{n}{x_1 \dots x_k} \phi_1^{x_1} \dots \phi_k^{x_k}$$

donde

$$\binom{n}{x_1 \dots x_k} = \frac{n!}{x_1! \dots x_k!}$$

RESULTADO: Sea $x \sim$ multinomial (n, ϕ) donde

$\tau = (x_1, \dots, x_k)^T$, $\phi = (\phi_1, \dots, \phi_k)^T$. Entonces la
distribución marginal de $x_j \sim$ Binomial (n, ϕ_j)

2. Distribución Normal Multivariada

Considerar $\mathbf{x} = (x_1, \dots, x_R)^T$, tal como el caso anterior se sigue de la distribución normal multivariada es caracterizada por un vector de medios $\mu = (\mu_1, \dots, \mu_R)^T$ y una matriz de covarianzas $\Sigma = (\sigma_{ij}) \geq 0$ y simétricas.

$\mathbf{x} \sim N_R(\mu, \Sigma)$.

Para el otro punto ideal considerar z_1, \dots, z_R

con dist. $N_1(0, 1)$. Y supongamos $\mathbf{z} = (z_1, \dots, z_R)^T$

$$\begin{aligned}
 f_z(z) &= \prod_{i=1}^R f_{z_i}(z_i) \\
 &= \prod_{i=1}^R (2\pi)^{-1/2} \exp \left\{ -\frac{1}{2} z_i^2 \right\} \\
 &= (2\pi)^{-R/2} \exp \left\{ -\frac{1}{2} \sum_{i=1}^R z_i^2 \right\} \\
 &= (2\pi)^{-R/2} \exp \left(-\frac{1}{2} \mathbf{z}^T \mathbf{z} \right).
 \end{aligned}$$

Y anotando $\mathbf{z} \sim N_R(0, I_R)$.

mas generalmente, $x \sim N_{\mathbb{R}^k}(\mu, \Sigma)$ tiene densidad

$$f(x) = \frac{1}{(2\pi)^{\frac{k}{2}}} |\Sigma|^{-\frac{1}{2}} \exp \left\{ -\frac{1}{2} (x-\mu)^T \Sigma^{-1} (x-\mu) \right\}$$

Dado que Σ es simétrica y definida positiva tenemos que $\Sigma = B B^T$. Esto lleva al resultado siguiente.

Resulado Si $z \sim N_{\mathbb{R}^k}(0, I)$ entonces $x = \mu + B z$ entonces $x \sim N_{\mathbb{R}^k}(\mu, \Sigma)$. Ahora si $x \sim N_{\mathbb{R}^k}(\mu, \Sigma)$ entonces $B^T(x-\mu) \sim N_{\mathbb{R}^k}(0, I)$.

Resulado. Sea $x \sim N_{\mathbb{R}^k}(\mu, \Sigma)$ y considere la partición

$$x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}, \quad \mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$$

Sala Agustina.

Entonces.

(a) La distribución marginal de $x_i \sim N_{k_i}(\mu_i, \Sigma_{ii})$, para $i=1, 2$.

(b) La distribución condicional de $x_2 | x_1 = x_1$ es

$$\textcircled{a} \quad f_2|x_1=x_1 \sim N_{k_2}\left(\mu_2 + \Sigma_{21}\Sigma_{11}^{-1}(x_1 - \mu_1), \Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12}\right)$$

$$\textcircled{b} \quad \Omega = (x - \bar{\mu})^T \bar{\Sigma}^{-1} (x - \bar{\mu}) \sim \chi_p^2$$

OBS: En efecto, recordar que $\mathbf{z} = (z_1, \dots, z_p)^T \sim N_p(0, I)$ (es decir z_1, \dots, z_p son i.i.d.)

$$\textcircled{c} \quad \Omega = \bar{\Sigma}_{22} = \sum_{i=1}^p z_i^2 \sim \chi_p^2$$